

Google Play Reviews — EDA Conclusion (Bilingual)

Google Play 评论数据 · 探索性数据分析结论 (中英双语)

1. Executive summary

1. 执行摘要

We deliver **10,940** English reviews after P0 cleaning ($\geq 10k$ requirement satisfied).

P0 清洗后英文子集 10,940 条，满足 10k+ 要求。

EDA Sections A–E cover distributions, patterns, language, token contrasts, and heuristic risk flags.

EDA A–E 覆盖分布、模式、语言、词频与启发式风险标记。

Risk flags are not ground truth — manual sampling is recommended.

风险标记非金标准，建议人工抽样后再下结论。

2. Data volume chain

2. 数据规模链路

Raw: **16,800** rows.

原始：16,800 行。

P0 all languages: **15,290** rows.

P0 全语言：15,290 行。

P0 English subset: **10,940** rows.

P0 英文：10,940 行。

English share on P0-all-lang: ~**71.5%**.

P0 全语言集中英文占比约 71.5%。

3. Core findings (see figures under reports/eda_section_*)

3. 核心发现 (图见 reports/eda_section_*)

A: rating & length distributions; length vs rating.

A : 评分与长度分布 ; 长度×评分。

B: per-app differences; daily volume; inconsistency & duplicate text probes.

B : 跨 App 差异、日趋势、评分-文本与重复文本探索。

C: language composition supports English-only modeling scope.

C : 语言构成支撑英文建模范围说明。

D/E: token highlights; heuristic spam/time flags — use cautiously.

D/E : 词频亮点 ; 刷评/时间启发式——谨慎使用。

4. Deliverables & next steps

4. 交付与下一步

Ship: cleaned exports, EDA artifacts, curated `reports/` tables, this PDF/PPT.

交付：清洗导出、EDA 产出、`reports/` 整理表、本 PDF/PPT。

Next: mentor chooses downstream focus (dashboard, sentiment/topic model, more data).

下一步：由 mentor 确定下游重点（看板、情感/主题模型、扩数据等）。