



■■■■■■■■ metrics.json ■ quality run ■ 2026-05-05 16:26:06

○、先说清「我们在看什么样本」

我们只看了 英文评论（约 10940 条），是从 Google Play 公开评论里抓到的一小部分。P0 清洗后英文占比约 0.7155。

所以所有结论都得加一句话：「只能代表愿意写英文评论的人」，不代表全部玩家、更不等于真金白银的留存付费。这是底线。

一、app_base_metrics.csv —— 一张 App 的「成绩单」

1.1 身份信息：它是谁、有多少人评价

- app_id / app_name：哪个 App。
 - n_reviews：这个 App 被算进来的英文评论条数。
- 说人话：样本多 = 数字更靠谱；样本少 = 偶然性大。后面所有「加权」「收缩」「打折」都是因为这个数。

1.2 大家普遍打几分

- mean_score (平均分)：所有人打的星算术平均。
→ 「总体感觉」。容易被极端分 (一堆 1★ 或 5★) 拉得很厉害。
- median_score (中位数)：把所有打分排成一队，正中间那个人打几分。
→ 「中间那个典型用户」打几分；不怕极端值。
- std_score (标准差)：分数有多分散。
→ 数值大 = 大家意见分歧大。注意：好评差评都很多也会让它变大，不一定就是「差评多」。

三个一起怎么读：mean 高、median 也高 = 真的好；mean 高但 median 低 (或反过来) = 一边倒 + 少量极端拉扯，要警惕。

1.3 五星结构 (最重要的一组)

- share_1 ~ share_5：每个星档的占比，加起来 = 100%。
- share_high_4_5 = 4★ + 5★ → 真心满意的人有多少。
- share_low_1_2 = 1★ + 2★ → 明确不满的人有多少。

为什么重要：平均分告诉你「分高低」，但这两个比例才告诉你「用户是分裂的、还是普遍开心 / 不爽」。后面 Health Score 里的「不满惩罚分」就直接吃 share_low_1_2。

1.4 清洗时打的「风险标签」

像 share_has_dev_reply (开发者回复率)、share_is_spam_bot_suspect (疑似刷评) 等。

说人话：这些只是「这条评论看起来有点怪」的提示，不是定罪。汇报时只能说「风险线索」，不能说「这家在刷评」。它们不进入 Health 合成。

二、Health Score —— 给 App 打综合分的「考试」

把 Health 想象成一场考试，当前权重（来自 metrics.json）：水位分占 40%，不满惩罚分占 35%，最近趋势分占 25%；最后再乘一个「评论够不够多」的可信度。

贝叶斯收缩参数 $k = 200$ ；可信度参考量 = 200 条；动量看最近 8 周（至少 3 个不同周才算回归斜率，否则退化为「后半段均分 - 前半段均分」）。

2.1 全班平均分（防偏科）

global_mean：把所有 App 的平均分按「评论条数」加权得到的「全班均分」，当前 ≈ 3.6755 。

bayesian_adjusted_avg（贝叶斯调整分）：评论太少，不能完全信你自己；要拉一把全班平均。

公式（人话版）：调整分 = (你自己的总分 + 全班平均 $\times$ 200) $\div$ (你的人数 + 200)。

评论很多 (n 远大于 200) $\rightarrow$ 几乎等于自己分；评论很少 (n 比 200 小很多) $\rightarrow$ 会被拉向全班均分。

为什么要这样？防止「只有 50 条评论但全是 5★」的小 App 莫名霸榜。

2.2 三个分数项（合成前的小分）

- component_level（水位分）= 调整分 $\div 5$ ，归一到 0-1。

$\rightarrow$ 「调整后的好评程度」。

- component_polarization（不满惩罚分）= $1 - \text{share_low_1_2}$ 。

$\rightarrow$ 「没在打低星的人占多大比例」。低星越多，这一项越低。

注意：它不看高分，只盯着 1-2 星——业务上「骂声」比「夸声」更值得警惕。

- component_momentum_01（最近趋势分）：最近 8 周里，每周平均星是涨是跌。涨 = 高分，跌 = 低分。

$\rightarrow$ 在本批 14 款里比着算，所以是「相对趋势」，不是绝对涨跌。

- component_confidence（可信度系数）= $\min(1, n_reviews \div 200)$ 。

$\rightarrow$ 「评论够不够多」。不到 200 条就打折，到了就封顶为 1。

2.3 最后的总分（一行公式说完）

预合成分 = $0.4 \times \text{水位} + 0.35 \times \text{不满惩罚} + 0.25 \times \text{趋势}$

最终 Health = 预合成分 $\times$ 可信度

大白话总结：「好评水位占大头 + 有没有差评集中 + 最近在涨还是在跌，再问一句『你写够答卷了吗』。」

health_score_rank：在这 14 款里按 Health 降序排第几名。只在本池有效，跨品类、跨地区不能直接比。

三、多个指标怎么「互相印证」（这才算看懂）

下面这张「场景 → 单看会错 → 一起看就清楚」的对照表，是判断你有没有真懂的核心。

- ① 平均分还行但排名靠后？
只看 mean 会冤枉。一起看：mean 不低 + share_low_1_2 高 → 不满惩罚分被压低 → Health 自然掉。
- ② 小 App 平均分超高？
只看 mean 会被骗。一起看：n 很小 → 贝叶斯把它拉向全班均分 → 可信度又打折一次，所以不会霸榜。
- ③ 趋势分 (momentum_01) 刚好 0.5？
可能不是「不涨不跌」，而是评论太稀疏走了退化算法。要回去看最近 8 周到底有多少条。
- ④ 比较两款 App 时只比 health？
容易判错。要并列看 n_reviews (影响贝叶斯 + 可信度) 和 pre_confidence (合成前分)。
- ⑤ 看发行方榜单？
publisher_benchmark 是按「评论条数」加权 (不是简单平均 App)。
公式： $\text{weighted_health} = \frac{\sum(\text{每款 health} \times \text{该款评论数})}{\sum(\text{评论数})}$ 。
→ 旗下评论多的 App 影响更大；要展开看每款的 share_low 与动量。
- ⑥ 散点图 (volume_vs_rating_scatter) 出现「高声量 + 低 Health」？
不是因果，只是两件事同时存在。要回到 app_base_metrics 拆 share_low 和 health 的 pre × conf。
- ⑦ app_benchmark_bq2 是什么？
= app_base_metrics 与 app_health_score 按 app_id 合并后的「竞品一页纸」。
→ 数值必须跟两张源表对得上，用于汇报对齐，不要在它上面再算一次。

四、用这套语言重读结论（本池当前快照）

下列每条结论都说清楚了「依赖哪些指标 / 它们如何互相印证」，是统计关联，不推断因果。数字会随 CSV 刷新而变。

4.0 Page 2 直接可贴版（汇报口吻）

用法：每条 = 一行结论 + 一行业务解读，可以直接复制到 PPT / 周报。最后一段是口播总结。

- 池内 Top 3 (Health Score) : Penny & Flo #1 (0.821, n=986)、Candy Crush Saga #2 (0.813, n=513)、Cookie Jam #3 (0.808, n=881)；三家共同点：低星 (1-2★) $\leq 20.4\%$ ，调整后均分 ≥ 3.90 。

业务解读：这 3 款是休闲消除赛道里「满意度结构最干净」的产品——不是均分高，而是差评比例被压到 22% 以内。可作为「成熟期休闲消除产品的差评天花板」基线，任何超过这个数的竞品都要打问号。

- 池内 Bottom 3 (重点观察名单) : Royal Kingdom #14 (0.355, n=859)、Royal Match #13 (0.583, n=684)、Homescapes #12 (0.664, n=672)；均出自 Match-3 / Match-3 + Decoration，1-2★ 占比均 $\geq 25.0\%$ 。

业务解读：这条产品线整体在评论端承压，且涉及多家头部发行方——大概率是「赛道用户审美/付费疲劳」而非单款做得不够精。立项提示：同玩法套壳已有疲劳信号，差异化 (玩法机制 / IP / 节奏) 比再做一款更值得投入。

- 发行方加权 Health 极差近 1.77× : SGN (Jam City) 0.808 (仅 1 款) 领跑；Dream Games 仅 0.456 垫底 (2 款，1543 条评论)，与 King 0.794 (2 款)、Tactile 0.785 (2 款) 形成断层。

业务解读：Dream 是评论端「系统性塌陷」，不是单款失误——是同品类后来者的机会窗。King / Tactile 在 0.78-0.79 的稳定带 = 同行业头部应有的水位，长期低于 0.7 就要正视问题。

- Royal Kingdom 是池内唯一「三红」案例：1-2★ 占比 60.7%、调整分仅 2.71 (远低于全班 3.68)、近 8 周趋势分 0.000。

业务解读：结构、水位、动量同时垫底，不是版本波动，是持续下行通道。可推动动作：拉低星评论文本做主题分析 (付费墙 / 广告 / 关卡难度 / bug)。对标分析时可作为「忽视低星结构的代价」反面案例。

- 声量 ≠ 满意度：Lily's Garden (n=997, Health #9, 0.749) 与 Royal Kingdom (n=859, Health #14, 0.355) 评论量相当，Health 差 0.39。

业务解读：「评论多 = 火」是伪命题——评论多很可能是因为用户来吐槽。做产品 / 市场决策必须配合 share_low_1_2 与调整分，不能只看下载量或评论数。建议在 PPT 里放散点图，让「高声量 + 低 Health」自然孤立出来。

- King 与 Tactile 是「稳健参照」：旗下产品 Health 落在 #1、#2、#7、#9，没有任何 1 款进入观察名单。

业务解读：他们是赛道基准线 (baseline)，不是超越目标。Top 1 常有运气成分 (IP / 首发红利)，真正可复制的成功是「旗下产品 Health 全部 ≥ 0.70 」——比追求一个 0.85 更可持续。

一段话收口（汇报口播版）

在我们这 14 款 Match-3 / 消除头部产品的池内，SGN、King、Tactile 三家在评论端形成稳定的高地 (Health 0.78-0.81)；Dream Games 是评论端系统性走弱的代表 (加权 Health 仅 0.46)，旗下 Royal Kingdom 出现「差评结构 + 调整分 + 趋势」三项指标同时垫底的极端情况，60.7% 的 1-2 星比例值得做主题级深挖。声量与满意度并非正相关——这是公开评论数据用于竞品分析时最容易踩的坑，也是为什么我们要同时报 Health 与 share_low_1_2，而不是只看评论数。

4.1 详细解释版（指标链推导）

下面 7 条是每条都展开「依赖哪些指标 → 怎么互相印证」的长版，适合放报告正文做支撑。

结论 1 — 榜首 vs 末位差距是「四件事一起发生」，不是单一原因：第 1 名「Penny & Flo」health ≈ 0.821 ；末位「Royal Kingdom」 ≈ 0.355 。

→ 不能光看平均分。要同时看：水位（贝叶斯调整分）+ 不满惩罚（share_low）+ 最近趋势 + 评论是否够多，四条线一起决定排名。

结论 2 — Dream Games 发行方加权 Health 垫底（ ≈ 0.456 ，2 款）：这是把旗下每款 health 按评论数加权得到的，所以是「整体观感都不好」，不是某一款拖。

→ 要可辩护，必须展开旗下每款的 share_low 与动量，不然丢细节。

结论 3 — Royal Kingdom 为什么垫底（三条腿同时塌）：① 结构差：1-2★ 占 60.7%；② 水位低：调整后均分 2.71（远低于全班 3.68）；③ 还在跌：趋势分 0.000；④ 评论 859 条够多了，可信度封顶为 1.00，没法再帮它打折回血。

→ 预合成分 $0.355 \times \text{可信度 } 1.00 = \text{health } 0.355$ 。三条腿同时塌，不是偶然。

结论 4 — Candy Crush Saga 为什么稳：高星 81.3%、低星只有 14.6%，调整分高，趋势中性偏稳；Health 排第 2。分量看：水位 0.815、不满惩罚 0.854、趋势 0.753、预合成分 0.813。

→ 头部产品不仅「均值好看」，低星结构也受控，与公式逻辑完全一致。

结论 5 — 全班均分 ≈ 3.6755 ：所有 App 的「贝叶斯调整分」都会向这个数靠拢。

→ 看到一款 App 调整分接近这个值，先怀疑是不是评论太少被「拉回」了，要把 n_reviews 一起拉出来看。

结论 6 — 发行方榜首「SGN (Jam City)」加权 Health ≈ 0.808 ，但本池只有 1 款

App：单产品发行方很容易「一好遮百丑」。

→ 汇报时一定要说「样本覆盖只有 1 款」，否则会被质疑跟 King、Dream Games 这种多款发行方做了不公平对比。

结论 7 — 「声量 vs 满意度」散点图怎么读：横轴 n_reviews、纵轴贝叶斯调整分或 Health。

→ 看到「高声量 + 低 Health」不要说成「差评的 App 反而火」；要回到 app_base_metrics 把 share_low、预合成分、可信度分别拉出来才说得清。

五、最后的「不要忘记」（局限性，固定要带）

- 公开评论有「自选择」与时间窗偏差；英文子集不代表全部语种用户。
- $k = 200$ 、权重、8 周动量窗口换了，排序就会变；可以做敏感度分析顺便展示稳健性。
- 「疑似刷评 / 异常时间」等启发式标签没有进入 Health 合成；汇报时跟 Health 分开讲。
- 趋势分（momentum_01）是本池内的相对排位，跨池不能比。

一句话记住

Health Score = 「好评水位 (40%) + 没差评的程度 (35%) + 最近是涨是跌 (25%)」 $\times$ 「你写够答卷了吗」。
单看一项都不准——四件事一起讲，结论才站得住。