

[illegible]

- data/processed/reviews_with_themes.csv —— 10940 条评论 + 每条命中的主题标签。
- reports/tables/theme_summary_overall.csv —— 「每个主题」的总账：被提多少次、平均几星、拉低评分多少。
- reports/tables/theme_summary_by_app.csv —— 「每个 App × 每个主题」的明细：用于 Page 3 的热力图。
- reports/tables/low_star_theme_summary.csv —— 「在 1-2 星里」哪些主题被骂最多。
- reports/tables/theme_validation_sample.csv —— 190 条抽样，留三列空白等人工校验。

四、新出现的字段：每个字段什么意思（说人话）

4.1 评论层（reviews_with_themes.csv）

- theme_tags：这条评论命中了哪些主题，用分号连接。
例：crash_bug;loading_performance 表示「同时在抱怨崩溃和卡顿」。
- n_themes_hit：这条评论一共命中了几个主题。
说人话：0 = 完全没被分类（可能是「Other」），数字越大代表越「啰嗦」、抱怨/夸奖了多件事。
- theme_<id>（如 theme_crash_bug）：18 个独立 0/1 标记。1 = 命中。
为什么这样存：方便 SQL / Excel / Power BI 做 group by 计算，不用再拆字符串。

4.2 主题层（theme_summary_overall.csv）

- theme_id / theme_label / category / polarity：主题的身份证。polarity = positive 代表是夸的主题，negative 代表是骂的主题。
- n_reviews：命中该主题的评论数量。
说人话：「这事儿被多少人吐槽 / 称赞过」。
- theme_share = n_reviews ÷ 总评论数。
说人话：「100 条评论里大概几条会聊到这个话题」。
- mean_score：命中该主题的评论的平均星级。
说人话：「提到这件事的人，普遍打几星」。
- rating_gap = 全体平均分 - 该主题平均分。
说人话：「一旦评论里提到这件事，平均评分会被拉低多少星」——正数越大 = 越伤评分。比如 crash_bug 的 rating_gap ≈ +1.28，意味着「评论里只要提一下崩溃，平均会少给 1.28 颗星」。
- share_low_1_2：命中该主题的评论里，1-2 星占比。
说人话：「提到这件事的人，有多少是直接打 1-2 星的差评」。这是「严重程度」的衡量。
- low_star_theme_share = 命中该主题的 1-2 星评论 ÷ 总的 1-2 星评论。
说人话：「所有的差评里，有多少是在骂这件事」。

4.3 App 层（theme_summary_by_app.csv）

- theme_share_in_app：在这个 App 内部，该主题占多少。
说人话：「这个 App 的评论里，多少%是在聊这件事」——可以用来比 App 之间的结构。
- rating_gap（按 App 算）：该 App 全体平均 - 该 App 内该主题的平均。
说人话：「在这个 App 自己内部，提这件事会被拉低多少星」——避免被跨 App 平均混淆。

4.4 校验样本（theme_validation_sample.csv）

- _source：这条样本是从哪个主题/分层抽出来的（low/mid/high 星 × 主题），方便回看抽样口径。
- precision_correct（留空）：人工填 Y/N ——「这条贴对了没？」用于估算准确率。
- missed_theme（留空）：人工填「漏贴了哪个主题」——用于估算漏召回（recall）。
- notes（留空）：人工写「为什么错 / 缺哪个关键词」，下一轮迭代字典时直接看这里。

五、新出现的函数 (核心逻辑 , 说人话)

5.1 _matches_theme(text, theme) —— 主题命中判断

做的事：把一条评论文本变小写，看它有没有踩到主题的关键词，同时排除「排除词」。
判定规则 (人话)：① 评论里出现任何一个排除词 → 直接判「不算」；② 否则只要命中任意一个关键词 → 判「算这个主题」。
例：「used to be fun」→ 命中 fun_addictive 的关键词「fun」，但也命中排除词「used to be fun」→ 最终不算正向主题 (修复了 v1 的错贴)。

5.2 themes.yml 的 keywords / exclude —— 字典是怎么改善的

v1 → v2 关键改动：

- ① Fun & Addictive 加了否定排除词 (not fun / used to be fun / takes the fun out 等) —— 把「曾经好玩、现在不好玩」识别为不算正向主题；
- ② Account & Login 收紧成短语：以前只要出现 login / account 就算，导致很多中性句子 (如 “great game and login is fast”) 被错贴。现在要求出现「login problem」「can't log」之类才算；
- ③ Difficulty & Progression 扩了词：too difficult / super hard / can't pass / stuck on the same level — 因为之前只覆盖「too hard」一种说法，漏掉了大量真痛点。

5.3 _band(score) —— 抽样分层

做的事：把每条评论按星级分成三档：low (≤2★) / mid (3★) / high (≥4★)。
为什么：抽样时每档都要抽，这样既能查「低星里错贴成正向主题」的精度问题，也能查「高星里漏贴正向主题」的召回问题。否则只抽低星会偏。

六、v1 → v2 字典自检的效果

指标	v1 (修前)	v2 (修后)	解读
整体打标覆盖率	45.8%	45.2%	微降，是「排除假阳性」该有的代价
低星(≤2★) 错贴成 Fun & Addictive	462 条	382 条	-17%，最大的「错贴正向」问题被压下
低星(≤2★) 命中 Difficulty & Progression	29 条	113 条	×3.9，原先漏召回的真痛点被找回
低星(≤2★) 命中 Account & Login	很高 (噪音大)	3 条	去掉裸 login/account 关键词后回归真问题

七、今天能直接说的数字 (汇报口径)

「一提就掉评分」的主题排行 (rating_gap 越大越伤)：

- Ads Quality：被 3 条评论提到，提到后平均评分被拉低 +2.68 星，其中 1-2★ 占比 100.0%。
- UI / Navigation：被 1 条评论提到，提到后平均评分被拉低 +2.68 星，其中 1-2★ 占比 100.0%。
- Pay-to-win / Greedy：被 154 条评论提到，提到后平均评分被拉低 +2.07 星，其中 1-2★ 占比 79.2%。
- Algorithm Fairness：被 62 条评论提到，提到后平均评分被拉低 +1.95 星，其中 1-2★ 占比 75.8%。
- Purchase Issue：被 35 条评论提到，提到后平均评分被拉低 +1.88 星，其中 1-2★ 占比 77.1%。

所有差评 (1-2★) 里被骂最多的主题：

- Fun & Addictive：占有所有差评的 12.2% (382 条) (正向主题在低星出现 = 大多是「以前好玩现在不好玩」讽刺语境，需要继续清洗)
- Crash & Bug：占有所有差评的 8.1% (252 条)
- Loading & Performance：占有所有差评的 5.7% (178 条)
- Pay-to-win / Greedy：占有所有差评的 3.9% (122 条)
- Difficulty & Progression：占有所有差评的 3.6% (113 条)

用户最爱称赞的 (正向主题，按提及次数排)：

- Fun & Addictive：3567 条提及 (占 32.6%)，平均 4.40 星。
- Story & Decoration：519 条提及 (占 4.7%)，平均 3.98 星。
- Visual & Graphics：239 条提及 (占 2.2%)，平均 4.57 星。

八、局限 / 下一步

- 字典是关键词匹配，无法理解反讽和拐弯。后续可加 LLM 二次审核。
- Fun & Addictive 仍夹杂了「广告里看起来好玩、实际不好玩」的吐槽 — Day 5 会考虑独立主题或并入 Ads Quality。
- 校验样本 (190 行) 还没有人工填 Y/N — 这是 Day 5 / Day 6 的事。